Laporan Tugas P2 — Representasi Data & Pra-pemrosesan

Klasifikasi Tingkat Obesitas dengan K-Nearest Neighbors (KNN)

Nama	Rizkya Gusnaldy Kalia
NIM	10124190
Mata Kuliah	Pembelajaran Mesin
Link data	https://www.kaggle.com/datasets/fatemehmehrparvar/obesity-levels
Link program	https://github.com/Bujanking1660/Prediction-of-Obesity-Levels-Based-On-Eating-Habits-and-Physical-Activites.git

1. Latar Belakang dan Tujuan

Obesitas merupakan masalah kesehatan yang terus meningkat. Memperkirakan tingkat obesitas seseorang dari kebiasaan sehari-hari (pola makan, konsumsi air, aktivitas fisik, moda transportasi, dan lainnya) dapat membantu deteksi dini tanpa pengukuran klinis. Tugas ini memprediksi tingkat obesitas (7 kelas) memakai algoritma KNN, dengan fokus pada pra-pemrosesan data: tipe kolom, missing values, duplikasi, kategori, normalisasi/standarisasi, outlier (IQR), ketidakseimbangan kelas, dan indikasi kebocoran data (*leakage*).

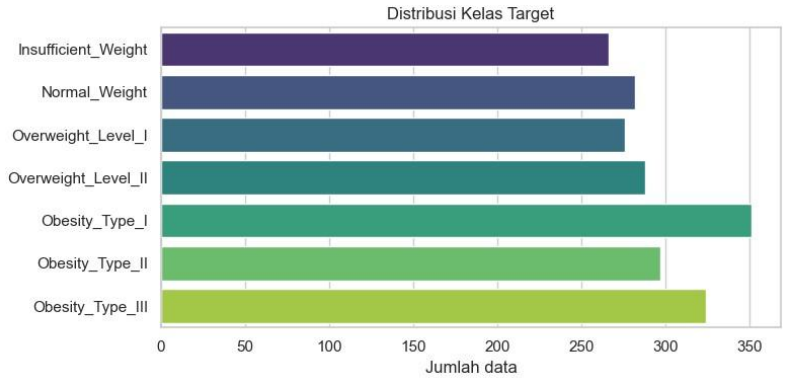
Dataset. *Estimation of Obesity Levels Based on Eating Habits and Physical Condition* (UCI Machine Learning Repository) berisi 2.111 baris dan 17 atribut: 16 fitur dan 1 target (7 kelas). Jumlah fitur memenuhi syarat minimal 10. Menurut dokumentasi UCI, 77% data dibuat sintetis dengan Weka dan filter SMOTE, sedangkan 23% dikumpulkan langsung dari pengguna melalui platform web [1][2]. File yang dipakai: `ObesityDataSet_raw_and_data_sinthetic.csv`.

2. Pemahaman Data

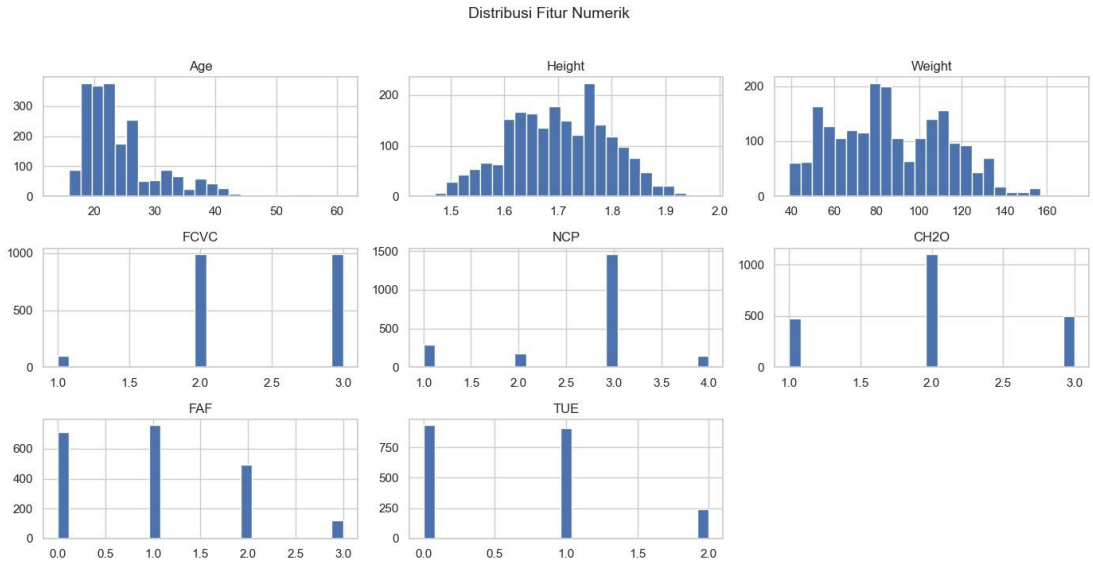
Kolom	**Keterangan**	**Tipe asli**	**Rentang / nilai**
Age	Usia (tahun)	float	14 – 61
Gender	Jenis kelamin	teks	Female, Male
Height	Tinggi badan (m)	float	1,45 – 1,98
Weight	Berat badan (kg)	float	39 – 173
CALC	Frekuensi konsumsi alkohol	teks (ordinal)	no, Sometimes, Frequently, Always

FAVC	Sering makan makanan berkalori tinggi	teks (biner)	no, yes
FCVC	Frekuensi konsumsi sayur	float (skor)	1 – 3
NCP	Jumlah makan utama per hari	float (skor)	1 – 4
SCC	Memantau asupan kalori	teks (biner)	no, yes
SMOKE	Merokok	teks (biner)	no, yes
CH2O	Konsumsi air harian	float (skor)	1 – 3
family_history_with_overweight	Riwayat keluarga kelebihan berat badan	teks (biner)	no, yes
FAF	Frekuensi aktivitas fisik	float (skor)	0 – 3
TUE	Waktu memakai perangkat teknologi	float (skor)	0 – 2
CAEC	Frekuensi ngemil di antara makan	teks (ordinal)	no, Sometimes, Frequently, Always
MTRANS	Moda transportasi utama	teks (nominal)	5 kategori
NObeyesdad	**Target**: tingkat obesitas	teks	7 kelas

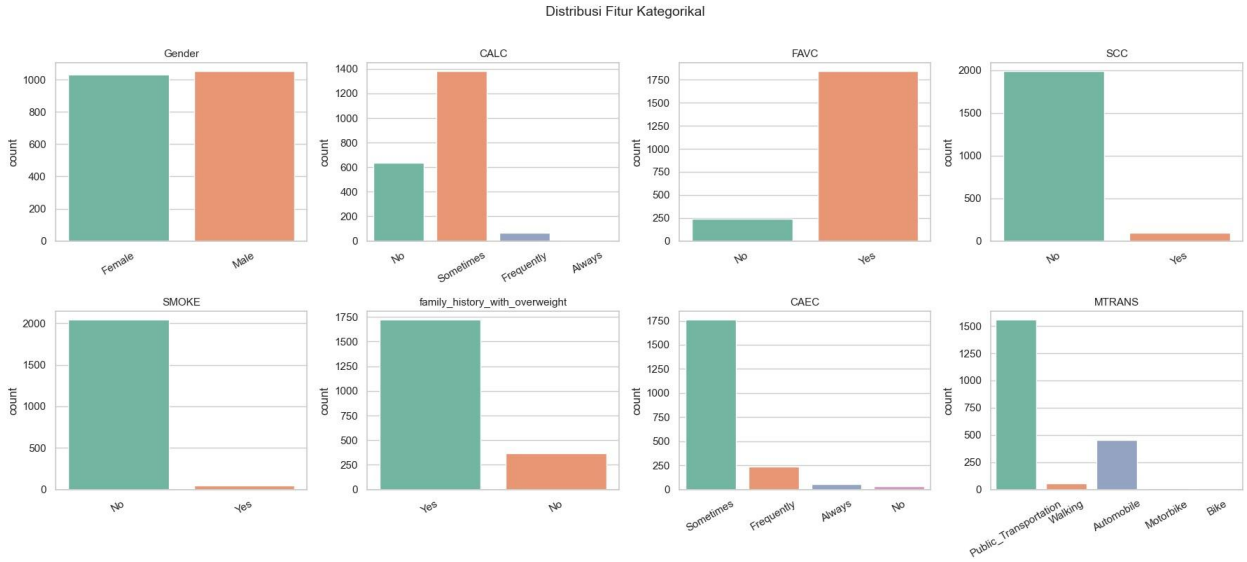
Visualisasi eksplorasi (dibuat dari data setelah pembersihan, 2.084 baris) memberi gambaran awal:



Gambar 1. *Distribusi kelas target. Tiap kelas berkisar 266–351 baris.*



Gambar 2. *Distribusi fitur numerik. Age condong ke usia muda dengan ekor panjang hingga 61 tahun; FCVC, NCP, CH2O, FAF, dan TUE berupa skor diskret.*



Gambar 3. *Distribusi fitur kategorikal. CALC dan CAEC didominasi "Sometimes", MTRANS didominasi transportasi umum, dan FAVC mayoritas "Yes".*

3. Pra-pemrosesan Data

3.1 Ringkasan tindakan

Aspek	**Kondisi data**	**Tindakan**	**Alasan**
Info & tipe kolom	Age, FCVC, NCP, CH2O, FAF, TUE berdesimal (Age 1.375 baris, CH2O 1.290, FAF 1.208, TUE 1.153, FCVC 826, NCP 640).	Dibulatkan dan diubah ke *int*. Kolom target diganti nama menjadi *Obesity_Level*.	Skor survei bermakna diskret. Desimal diduga artefak SMOTE.

Missing values	0 nilai hilang (NaN maupun nilai tersembunyi seperti spasi, “?”, “-”).	Tidak ada tindakan.	Data lengkap.
Duplikasi	27 baris duplikat persis (1,28%) setelah pembulatan; 24 baris pada file mentah.	Dihapus sebelum split: 2.111 → 2.084 baris.	Mencegah baris yang sama muncul di data latih dan uji.
Kategori	Kapitalisasi tidak seragam (“no/yes” huruf kecil vs “Sometimes/Frequently/Always”).	*strip* spasi dan *capitalize*.	Pemetaan encoding konsisten.
Encoding	8 kolom teks + target.	Biner → 0/1; ordinal → 0–3; MTRANS → one-hot; target → 0–6.	KNN memakai jarak sehingga semua fitur harus numerik.
Outlier (IQR)	Age: 160 outlier (7,68%) di atas 35 tahun.	*Capping* ke batas IQR dari data latih (11–35).	Menjaga jumlah data dan mengurangi pengaruh nilai ekstrem pada jarak.
Imbalance kelas	Rasio kelas terbesar : terkecil = 1,32 : 1.	Tidak di-resample; split memakai *stratify*.	Hampir seimbang.
Leakage	Weight dan Height membentuk BMI yang diduga menentukan label.	Kedua kolom dibuang dari fitur.	Model diarahkan belajar dari kebiasaan hidup.
Normalisasi & standarisasi	Skala fitur berbeda (Age 15–35 vs FCVC 1–3).	Min-Max dan Z-score dibandingkan; scaler hanya di-*fit* pada data latih.	KNN berbasis jarak; mencegah kebocoran dari data uji.

3.2 Encoding

Jenis	**Kolom**	**Pemetaan**
Biner	Gender, FAVC, SCC, SMOKE, family_history_with_overweight	Gender: Female = 0, Male = 1. Lainnya: No = 0, Yes = 1.

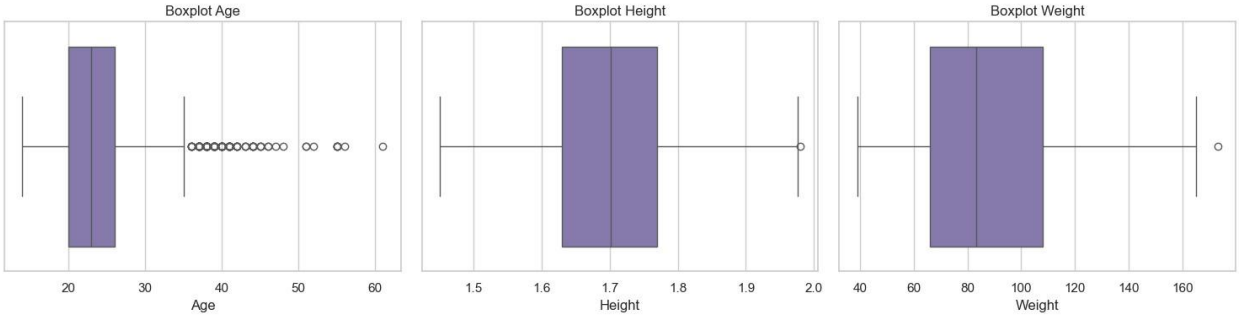
Ordinal	CALC, CAEC	No = 0, Sometimes = 1, Frequently = 2, Always = 3
Nominal (one-hot)	MTRANS	5 kolom: Automobile, Bike, Motorbike, Public_Transportation, Walking
Target	Obesity_Level	Insufficient_Weight = 0, Normal_Weight = 1, Overweight_Level_I = 2, Overweight_Level_II = 3, Obesity_Type_I = 4, Obesity_Type_II = 5, Obesity_Type_III = 6

Setelah encoding data berukuran 21 kolom (termasuk target). Setelah Weight dan Height dibuang (bagian 3.6) tersisa 18 fitur. MTRANS di-*one-hot* karena tidak punya urutan, sehingga jarak antar kategori tidak diasumsikan.

3.3 Outlier (metode IQR)

Batas dihitung dengan IQR = Q3 − Q1; batas bawah = Q1 − 1,5×IQR dan batas atas = Q3 + 1,5×IQR. Aturan 1,5×IQR dipakai pada kolom numerik kontinu *Age*, *Height*, dan *Weight*.

Fitur	**Batas bawah**	**Batas atas**	**Jumlah outlier**	**Persen**	**Tindakan**
Age	11,00	35,00	160	7,68%	Capping (batas dari data latih)
Height	1,42	1,98	1	0,05%	Dipertahankan (masuk akal)
Weight	2,96	171,06	1	0,05%	Dipertahankan (masuk akal)



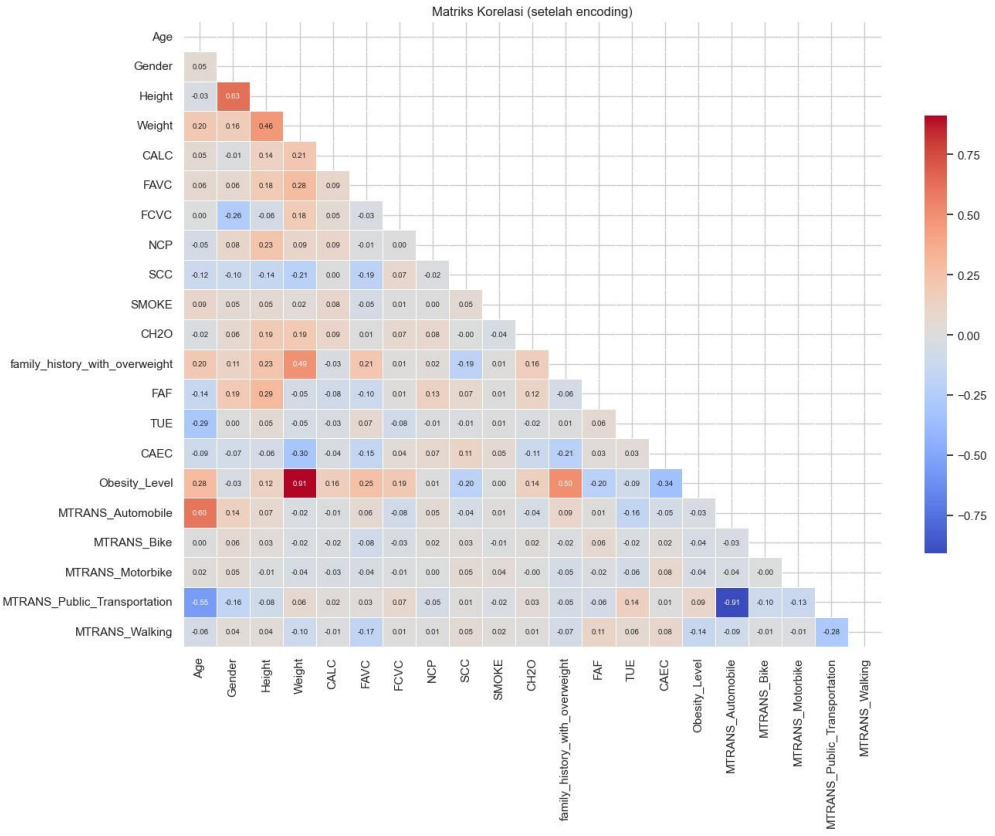
Gambar 4. *Boxplot Age, Height, dan Weight. Age memiliki banyak titik di atas batas atas (35).*

Tidak ada baris yang dihapus. Pada *Age*, nilai di atas 35 diganti menjadi 35 (*winsorizing/capping* [3][4]) karena usia tua adalah nilai valid yang jarang muncul, sedangkan pada KNN selisih besar dapat mendominasi jarak. Batas IQR dihitung hanya dari data latih lalu dipakai pada data latih dan uji. Nilai

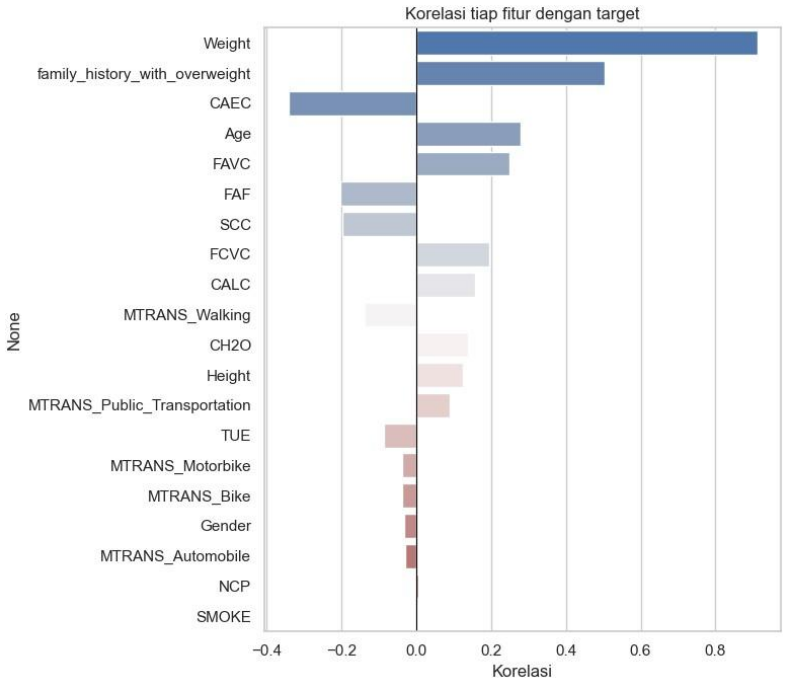
35 adalah hasil perhitungan IQR, sedangkan pemilihan capping pada *Age* adalah keputusan analisis saya. Konsekuensinya, perbedaan antar usia di atas 35 tidak lagi dibedakan model.

3.4 Ketidakseimbangan kelas

Setelah duplikat dihapus, jumlah data per kelas: Insufficient_Weight 266, Normal_Weight 282, Overweight_Level_I 276, Overweight_Level_II 288, Obesity_Type_I 351, Obesity_Type_II 297, dan Obesity_Type_III 324 (Gambar 1). Rasio kelas terbesar terhadap terkecil adalah **1,32 : 1**, sehingga tidak ada masalah imbalance yang berarti dan resampling tambahan tidak diperlukan. Keseimbangan ini bukan kondisi alami populasi, melainkan konsekuensi penggunaan SMOTE oleh pembuat dataset. Pembagian data tetap memakai *stratify* agar proporsi kelas terjaga. **3.5 Korelasi antar fitur**



Gambar 5. *Matriks korelasi setelah encoding (sebelum Weight dan Height dibuang).*



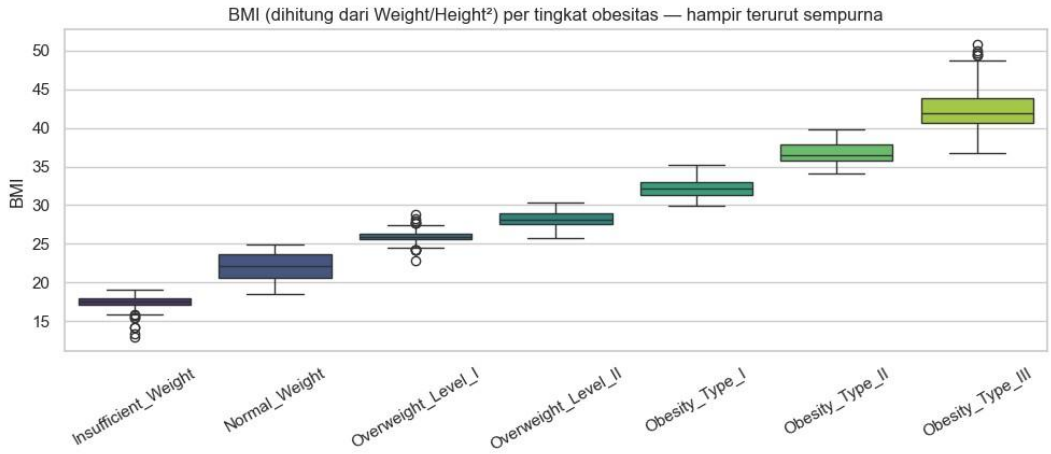
Gambar 6. *Korelasi tiap fitur dengan target.*

Weight memiliki korelasi 0,91 dengan target, jauh di atas fitur lain. Fitur berikutnya: riwayat keluarga (0,50), CAEC (−0,34), Age (0,28), dan FAVC (0,25). NCP dan SMOKE hampir tidak berkorelasi linear dengan target (0,01 dan 0,00). Korelasi −0,91 antara MTRANS_Automobile dan MTRANS_Public_Transportation wajar karena keduanya hasil one-hot dari kolom yang sama. Korelasi hanya mengukur hubungan linear dan tidak berarti sebab-akibat.

3.6 Indikasi kebocoran data (leakage)

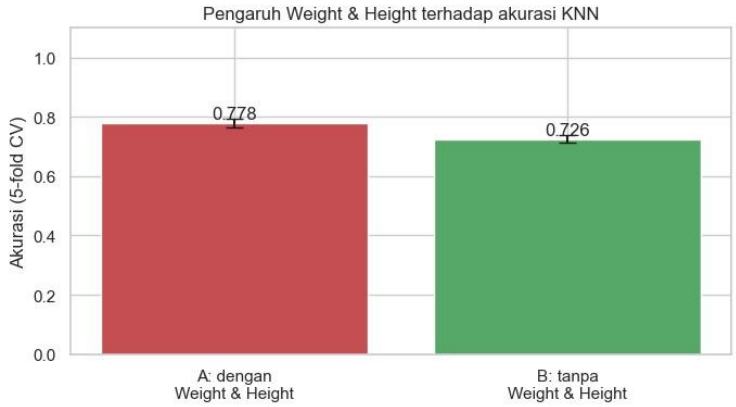
Korelasi Weight dengan target yang sangat tinggi mendorong pengecekan BMI = Weight / Height². Rentang BMI per kelas:

Kelas	**BMI min**	**BMI rata-rata**	**BMI maks**
Insufficient_Weight	13,0	17,4	19,1
Normal_Weight	18,5	22,0	24,9
Overweight_Level_I	22,8	26,0	28,8
Overweight_Level_II	25,7	28,2	30,4
Obesity_Type_I	29,9	32,3	35,2
Obesity_Type_II	34,0	36,7	39,8
Obesity_Type_III	36,8	42,3	50,8



Gambar 7. *BMI (Weight/Height²) per tingkat obesitas. Urutannya jelas, dengan sedikit tumpang tindih di batas antar kelas.*

Rata-rata BMI naik konsisten dari kelas ringan ke berat, dengan tumpang tindih kecil di batas antar kelas (paling lebar pada Overweight_Level_I dan II). Pola ini menunjukkan label diduga ditentukan dari BMI. Dugaan ini berasal dari pola data dan belum saya cocokkan dengan dokumentasi pembuat dataset. Untuk melihat dampaknya pada KNN dilakukan 5-fold cross-validation (K = 5):



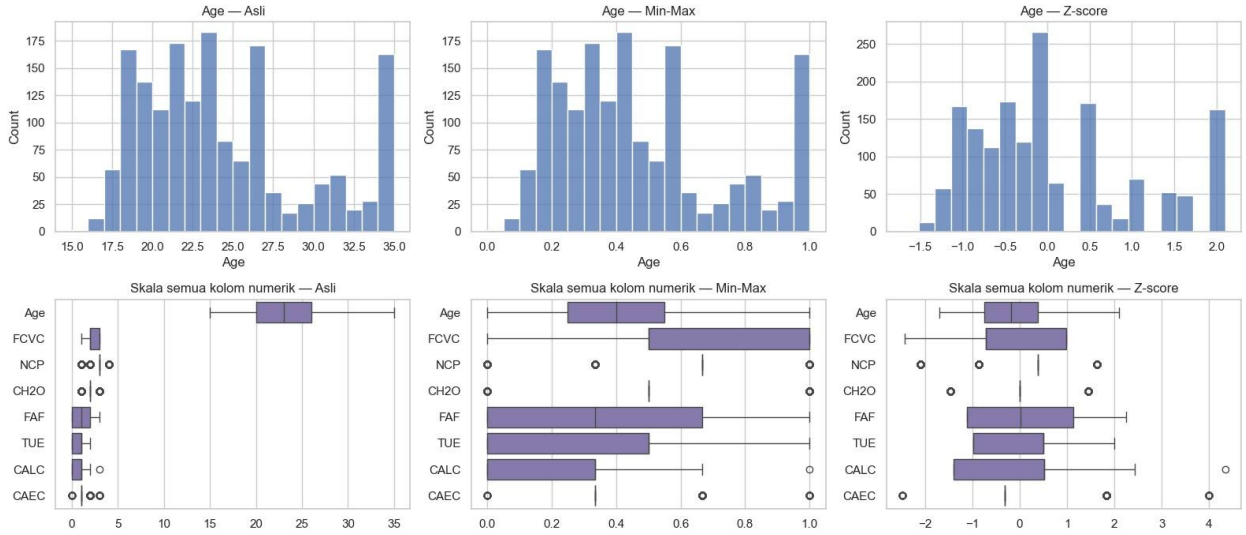
Gambar 8. *Akurasi KNN (5-fold CV, K = 5) dengan dan tanpa Weight & Height: 0,778 vs 0,726 (77,83% ± 1,43 vs 72,55% ± 1,23).*

Keputusan: Weight dan Height dikeluarkan dari fitur, karena tujuannya memprediksi dari kebiasaan makan dan aktivitas, bukan merekonstruksi rumus BMI. Keduanya dibuang bersamaan karena BMI dibentuk dari kombinasi keduanya. Kenaikan akurasi saat keduanya ikut dipakai tergolong moderat (sekitar 5 poin persentase).

3.7 Split data, normalisasi, dan standarisasi

Urutan pengerjaan: (1) buang Weight dan Height, (2) bagi data secara stratified 80:20 (1.667 data latih, 417 data uji, *random_state* = 42), (3) hitung batas outlier *Age* dan *fit* scaler hanya dari data latih, lalu terapkan ke data latih dan uji. Normalisasi (Min-Max) memetakan nilai ke 0–1, sedangkan

standarisasi (Z-score) membuat rata-rata 0 dan simpangan baku 1. Kolom yang diskalakan adalah 8 kolom non-biner: Age, FCVC, NCP, CH2O, FAF, TUE, CALC, dan CAEC; kolom biner/one-hot sudah berada pada rentang 0–1.



Gambar 9. *Age dan skala semua kolom numerik: asli, Min-Max, dan Z-score. Sebelum diskalakan, Age (15–35) berskala jauh lebih besar daripada kolom lain (0–4).*

3.8 Hasil pra-pemrosesan: 5 data teratas dan 5 data terbawah

Data setelah dibersihkan dan di-encode (sebelum split dan scaling), 2.084 baris × 19 kolom (18 fitur + target). Tabel ditampilkan secara transpos: baris = atribut, kolom = nomor baris data.

5 data teratas

Atribut \ baris	**0**	**1**	**2**	**3**	**4**
Age	21	21	23	27	22
Gender	0	0	1	1	1
CALC	0	1	2	2	1
FAVC	0	0	0	0	0
FCVC	2	3	2	3	2
NCP	3	3	3	3	1
SCC	0	1	0	0	0

SMOKE	0	1	0	0	0
CH2O	2	3	2	2	2
family_history_with_overweight	1	1	1	0	0
FAF	0	3	2	2	0
TUE	1	0	1	0	0
CAEC	1	1	1	1	1
Obesity_Level	1	1	1	2	3
MTRANS_Automobile	0	0	0	0	0
MTRANS_Bike	0	0	0	0	0
MTRANS_Motorbike	0	0	0	0	0
MTRANS_Public_Transportation	1	1	1	0	1
MTRANS_Walking	0	0	0	1	0

5 data terbawah

Atribut \ baris	**2079**	**2080**	**2081**	**2082**	**2083**
Age	21	22	23	24	24
Gender	0	0	0	0	0
CALC	1	1	1	1	1
FAVC	1	1	1	1	1
FCVC	3	3	3	3	3
NCP	3	3	3	3	3
SCC	0	0	0	0	0
SMOKE	0	0	0	0	0
CH2O	2	2	2	3	3

family_history_with_overweight	1	1	1	1	1
FAF	2	1	1	1	1
TUE	1	1	1	1	1
CAEC	1	1	1	1	1
Obesity_Level	6	6	6	6	6
MTRANS_Automobile	0	0	0	0	0
MTRANS_Bike	0	0	0	0	0
MTRANS_Motorbike	0	0	0	0	0
MTRANS_Public_Transportation	1	1	1	1	1
MTRANS_Walking	0	0	0	0	0

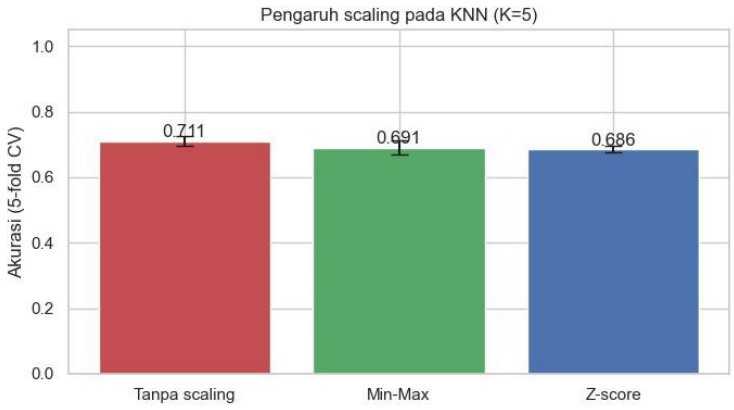
Catatan: pada program, 5 teratas/terbawah data latih setelah capping dan standarisasi juga ditampilkan.

4. Pemodelan KNN dan Evaluasi

4.1 Pengaruh scaling pada KNN

Perbandingan akurasi (5-fold CV pada data latih, K = 5):

Transformasi	**Akurasi rata-rata CV**	**Simpangan baku**
Tanpa scaling	71,09%	0,0145
Normalisasi (Min-Max)	69,05%	0,0208
Transformasi	**Akurasi rata-rata CV**	**Simpangan baku**
Standarisasi (Z-score)	68,57%	0,0104

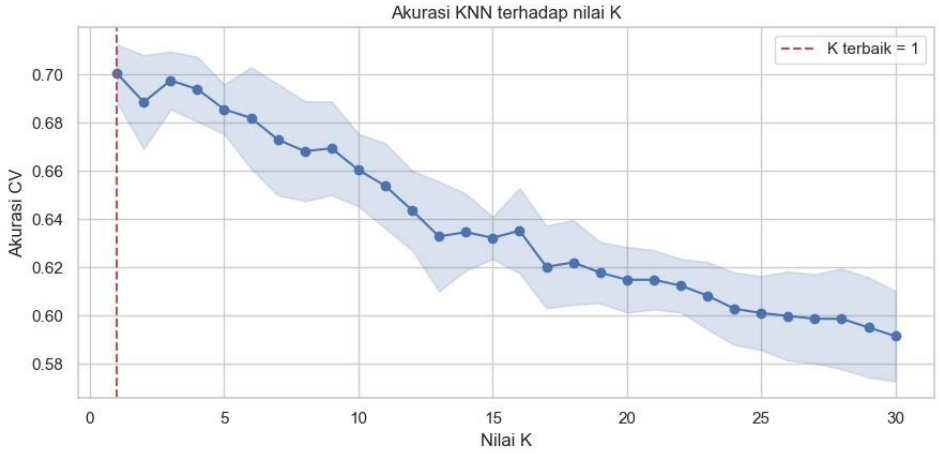


Gambar 10. *Pengaruh scaling pada akurasi KNN (K = 5, 5-fold CV).*

Pada data ini, scaling tidak meningkatkan akurasi; tanpa scaling justru sedikit lebih tinggi (selisih sekitar 2–3 poin persentase). Penyebab pastinya belum diuji. Standarisasi Z-score tetap dipakai pada model final karena merupakan praktik baku untuk algoritma berbasis jarak dan simpangan bakunya paling kecil (0,0104), dengan catatan bahwa keunggulannya pada data ini tidak terbukti.

4.2 Pencarian nilai K

Nilai K = 1 sampai 30 diuji dengan Z-score dan 5-fold CV pada data latih (data uji belum disentuh).



Gambar 11. *Akurasi CV terhadap nilai K. Akurasi tertinggi pada K = 1 (70,07%) dan cenderung menurun seiring K bertambah.*

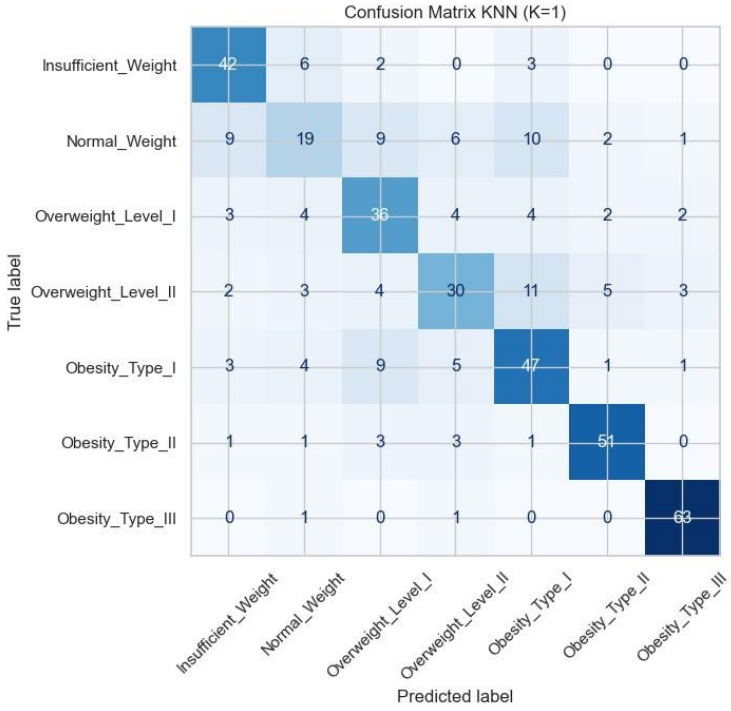
K terbaik adalah K = 1 dengan akurasi CV 70,07%. Hasil ini patut dicurigai: K = 1 sangat sensitif terhadap noise. Dugaan saya, karena 77% data adalah titik sintetis SMOTE hasil interpolasi, sebuah titik sering punya "kembaran" dekat di data lain, sehingga K = 1 dapat menang hanya dengan menyalin label tetangga terdekat. Dugaan ini belum diuji.

4.3 Evaluasi pada data uji

Model final (K = 1, Z-score) dilatih pada seluruh data latih dan diuji sekali pada 417 data uji. Akurasi data uji: 69,06% (288 dari 417 benar); macro F1 = 0,677 dan weighted F1 = 0,682.

Kelas	Precision	Recall	F1-score	Support
Insufficient_Weight	0,700	0,792	0,743	53
Normal_Weight	0,500	0,339	0,404	56
Overweight_Level_I	0,571	0,655	0,610	55
Overweight_Level_II	0,612	0,517	0,561	58
Obesity_Type_I	0,618	0,671	0,644	70

Obesity_Type_II	0,836	0,850	0,843	60
Obesity_Type_III	0,900	0,969	0,933	65
Kelas	**Precision**	**Recall**	**F1-score**	**Support**
Macro average	**0,677**	**0,685**	**0,677**	**417**



Gambar 12. *Confusion matrix KNN (K = 1) pada data uji.*

Dari confusion matrix, kelas ekstrem paling mudah dikenali: Obesity_Type_III benar 63 dari 65 (F1 0,933) dan Obesity_Type_II benar 51 dari 60 (F1 0,843). Kelas tengah paling sulit: Normal_Weight hanya benar 19 dari 56 (F1 0,404) dan sering tertukar dengan Obesity_Type_I (10), Insufficient_Weight

(9), dan Overweight_Level_I (9). Overweight_Level_II sering salah diprediksi sebagai Obesity_Type_I (11). Kemungkinan penyebabnya adalah kebiasaan hidup pada kelas bertetangga yang saling tumpang tindih, tetapi ini belum diuji lebih lanjut.

5. Kesimpulan dan Keterbatasan

Kesimpulan

- Dataset memenuhi syarat tugas (2.111 baris, 16 fitur, klasifikasi 7 kelas). Pra-pemrosesan yang dilakukan: koreksi tipe, cek missing (0), hapus 27 duplikat, rapikan kategori, encoding, analisis outlier IQR dengan capping pada Age, analisis imbalance (1,32 : 1), dan penanganan indikasi leakage.

- Weight dan Height dikeluarkan karena diduga membentuk label lewat BMI (korelasi Weight dengan target 0,91; akurasi CV 77,83% dengan keduanya dan 72,55% tanpa keduanya).
- Scaler dan batas outlier hanya dihitung dari data latih, dan duplikat dihapus sebelum split, untuk mencegah kebocoran dari data uji.
- Pada data ini scaling tidak meningkatkan akurasi KNN (tanpa scaling 71,09%, Min-Max 69,05%, Z-score 68,57%).
- Model final KNN (K = 1) mencapai akurasi uji 69,06%. Model mengenali kelas ekstrem dengan baik (Obesity_Type_III F1 0,933), tetapi kesulitan pada Normal_Weight (F1 0,404) dan kelas overweight.

Keterbatasan

- Sekitar 77% data sintetis (SMOTE), sehingga akurasi mungkin lebih optimistis dari performa pada data nyata, dan K = 1 yang unggul diduga terkait hal ini.
- Dugaan bahwa label ditentukan dari BMI berasal dari pola data, belum dikonfirmasi ke dokumentasi pembuat dataset.
- Hasil berasal dari satu kali pembagian data latih/uji (*random_state* = 42).

Referensi

[1] Palechor, F. M., & De la Hoz Manotas, A. (2019). Dataset for estimation of obesity levels based on eating habitsand physical condition in individuals from Colombia, Peru and Mexico. *Data in Brief*, 25. https://doi.org/10.1016/j.dib.2019.104344

[2] UCI Machine Learning Repository. *Estimation of Obesity Levels Based On Eating Habits and Physical Condition*. https://archive.ics.uci.edu/dataset/544

[3] Feature-engine. *Winsorizer* (dokumentasi). https://feature-engine.trainindata.com/en/1.8.x/api_doc/outliers/Winsorizer.html

[4] Train in Data. *Winsorization: Handling Outliers in Machine Learning*. https://blog.trainindata.com/winsorization-handling-outliers-in-machine-learning/